

ネットワーク分析を用いた誘い出し ・ネットいじめの検知

**東京大学 大学院工学系研究科
西口 真央**

プロジェクトの全体像

未成年者が抱える 観測困難なネット利用リスクの軽減※

グループ	関係組織	テーマ
システム グループ	東京大学 サイバーエージェント ナナメウエ エースチャイルド LINE	未成年者のネットリスクを軽減するための <u>リスク検知システムの開発</u>
教育 グループ	関東学院大学 エースチャイルド	未成年者が自らリスクに気づくための <u>ネットリスク教育法の開発</u>
社会 グループ	中央大学	ステークホルダーにシステム導入を促すための <u>インセンティブ設計</u>

2,458人のオオカミたちから届いた危険な誘い—
世界を震撼させた衝撃のリアリティーショー！

少女たちの10日間

監督: バーラ・ハルボヴァー、ヴィート・クルサーク 原案: ヴィート・クルサーク
出演: テレザ・チェジュカー、アネジュカ・ピタルトヴァー、サビナ・ドロウバー
字幕翻訳: 小山美穂 字幕監修: 牧野ズザナ 配給: ハーク
2020年 / チェコ / チェコ語 / ビスタ / 原題: V sítí / 104分 R15+

Hypermarket Film Czech Television Peter Kerekes Radio and Television Slovakia Helium Film
Sabina Dlouhá (Nicky), Anežka Pithorová (Teeny), Tereza Těška (Mishka)
Written and Directed by Barbora Chalupová & Vít Klusák Director of Photography Adam Kruliš
Sound Edam Bláha, Music Pjoni Film Editor Vít Klusák Production Designer Jon Vlček
Costume Designer Veronika Trábusová Make-up Artist Barbora Paruzíková
Digital Masks Designer Plottik Head of Production Anna Poláčková Executive Producer Pavla Klimešová
Producers Vít Klusák & Filip Remunda Distributor Ruffook Filmoslovenské

©2020 Hypermarket Film, Czech Television, Peter Kerekes, Radio and Television of Slovakia, Helium Film All Rights Reserved.

- 2020年
国際ファンタスティック映画祭
正式出品
- 2020年
コペンハーゲン
国際ドキュメンタリー映画祭
正式出品
- 2020年
ベルゲン
国際映画祭
正式出品
- 2020年
モントリオール
ニューシネマ
映画祭
正式出品

リアルの恐怖とフェイクの快樂

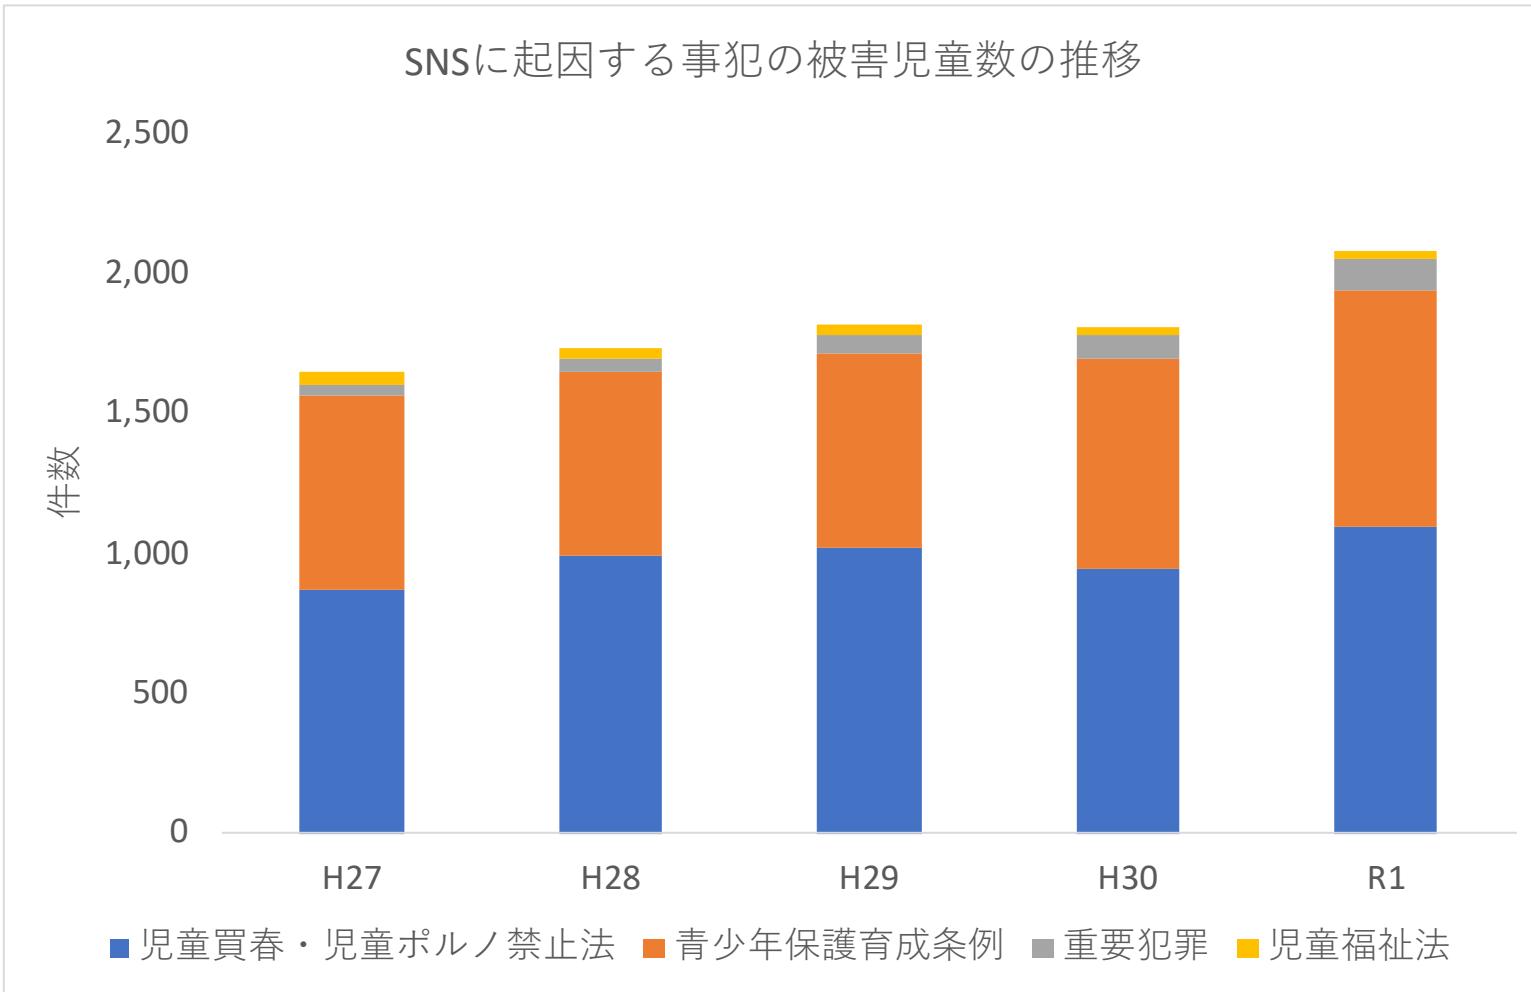


※「少女たちの10日間」オフィシャルサイト, <http://www.hark3.com/sns-10days/>

誘い出し等の被害の現状

■ 全体の件数、重要犯罪の件数が増加傾向

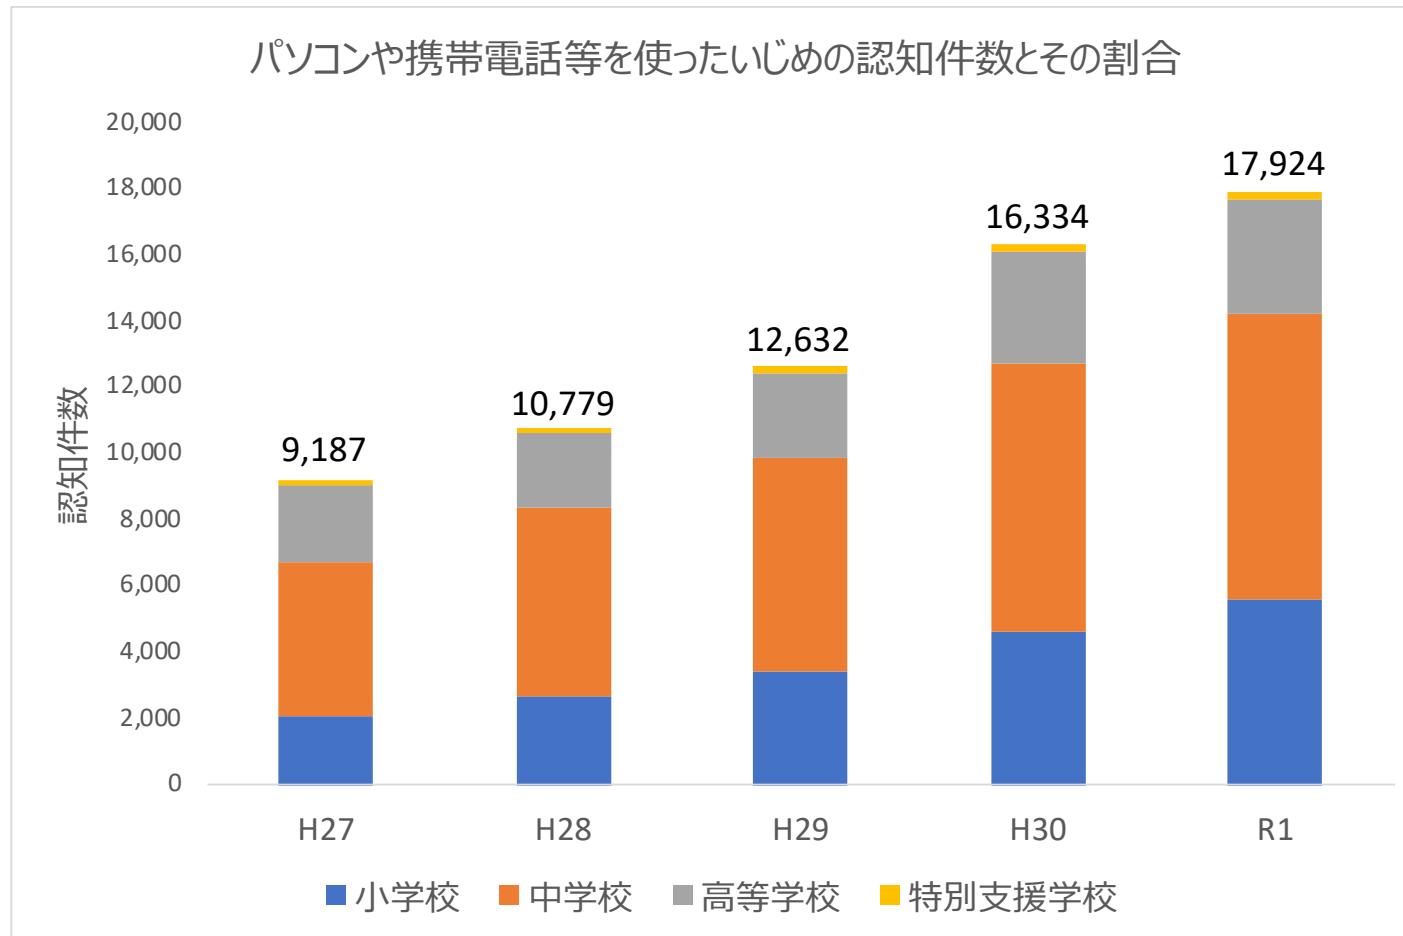
- ・ 座間事件、茨城女子大生殺人事件、某youtuberなど



ネットいじめ被害の現状

■ 同様に増加傾向

- 特に小学校の認知件数が顕著



実装する2つのシステム

- 「誘い出し加害者」と「いじめ被害者」の検知システムを構築
- 実サービスでの運用を見据えた共同研究

誘い出しユーザの検知



- ・ピグパーティとの共同研究
- ・誘い出し行為を行なっている可能性の高いユーザ集合を出力
- ・有人監視を経て、ペナルティの付与やアカウントBANの実行

いじめ被害者の検知



- ・子供見守りアプリfiliiとの共同研究
- ・ネットいじめの予兆を確率で出力
- ・本人と保護者に自動アラート送信, 啓蒙情報の提供

誘い出し ユーザの検知



ピグパーティとは



仮想空間内でなりきりたいアバター（ピグ）を作って、
ピグのきせかえや、自分のお部屋のもようがえをしながら楽しむ
アバターコミュニケーションアプリです。



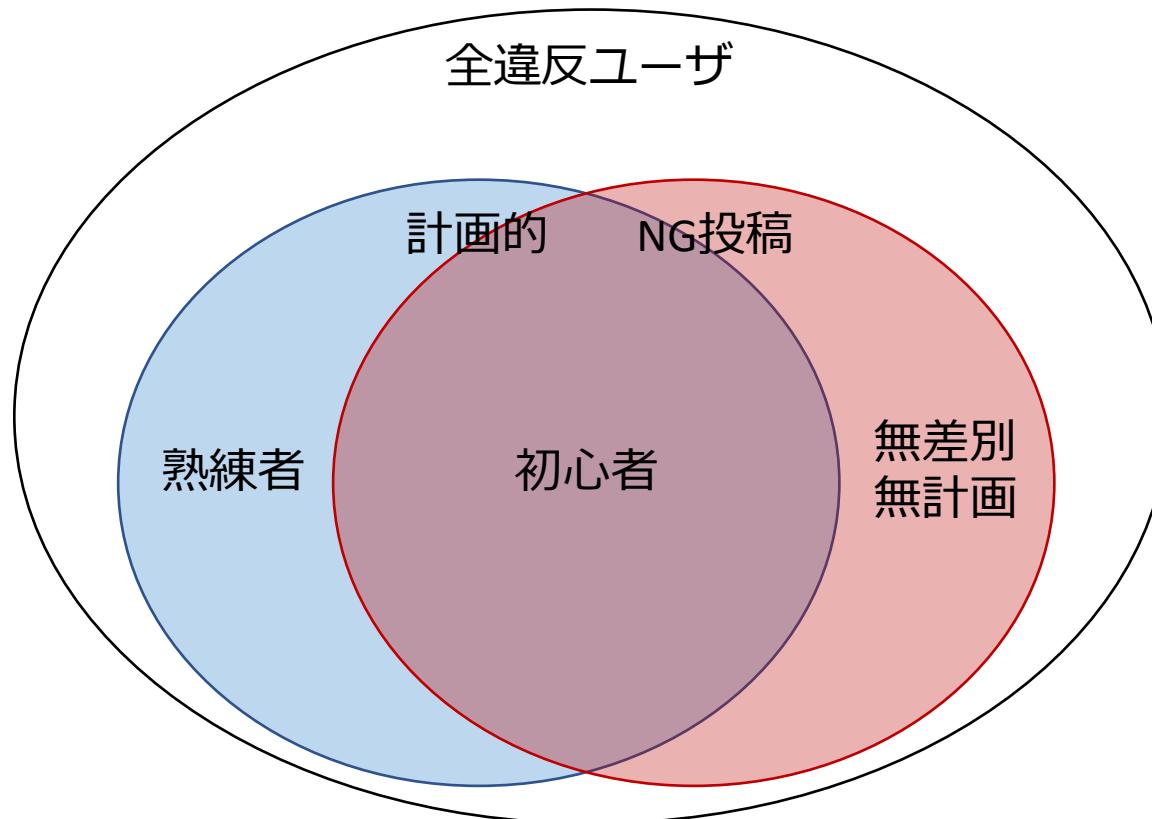
違反ユーザのカテゴライズ

■ 計画的 or 無差別

- ・ 無差別な違反は低レベルなものが多い
- ・ まず検知すべきは計画的な違反ユーザ

■ 初心者 or 熟練者

- ・ 熟練者をNGワードで検知することは困難

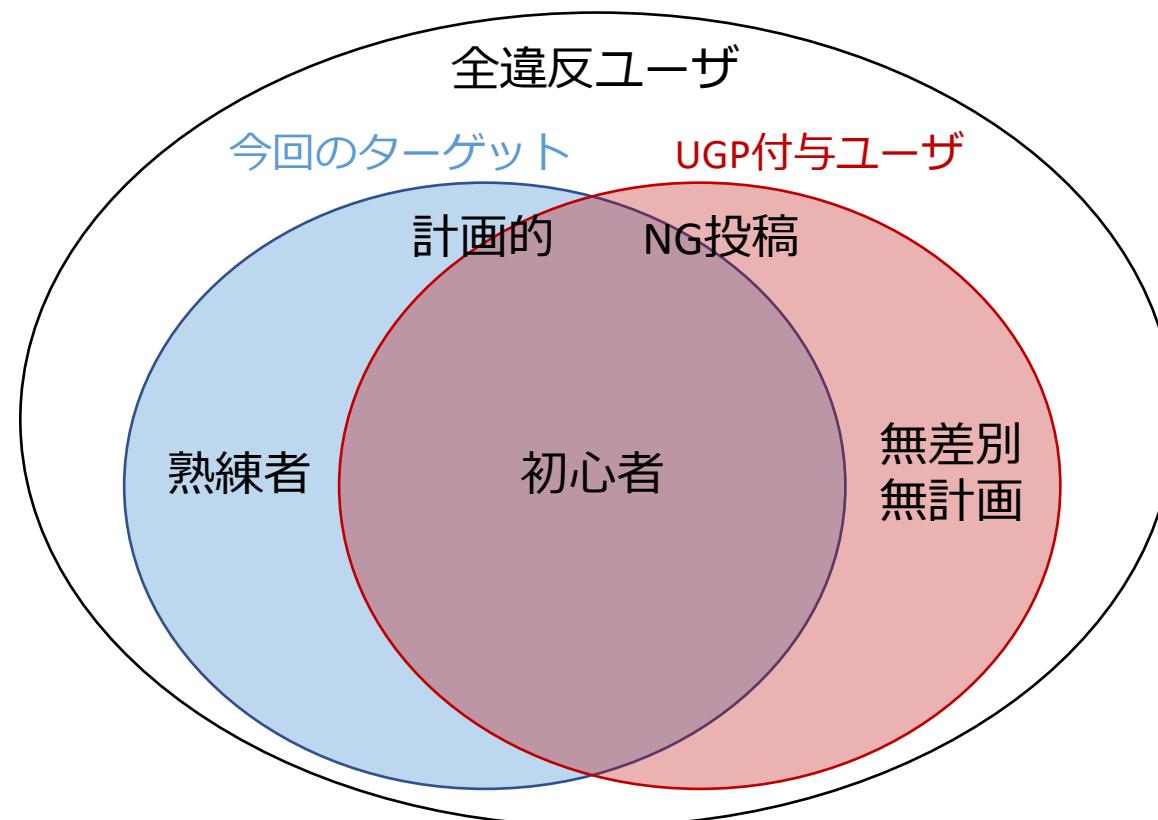


本システムの役割

- たとえNGワードを学習しても、接触するユーザは変わらないのでは？



- 計画的な初心者の接触行動をモデル化して、熟練者を発見



SNS違反検知システムの重要ポイント

■ プライバシー

- ・ 通信の秘密：プライベートなテキストデータの利用が困難
- ・ 個人情報保護：ユーザを特定し得るデータの利用が困難

■ 全自動化が困難

- ・ AIの暴走
- ・ 「怪しい」だけではBANできない

■ 多様な機能

- ・ トーク、パーティ、コミュなど多様な機能があり、SNSによっても異なる

■ コンテンツの流動性

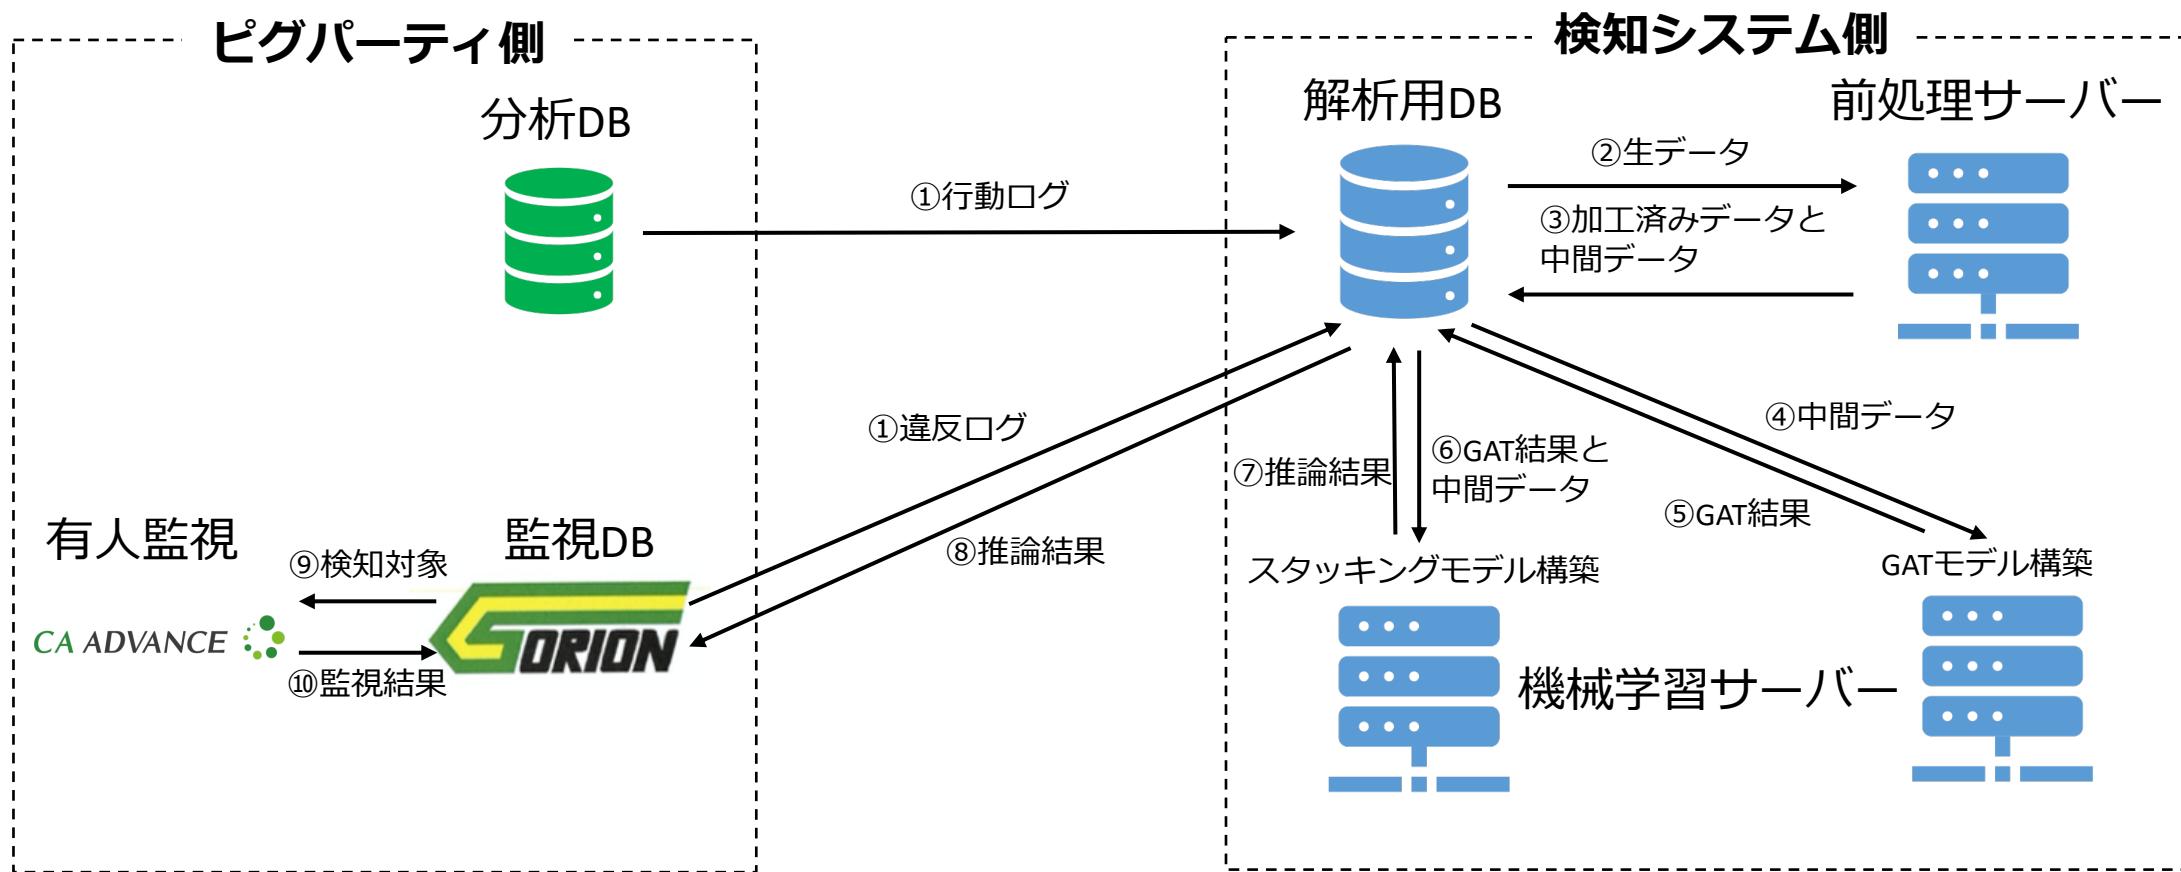
- ・ チャットルームや投稿などのコンテンツは常に入れ替わる

■ クラスの不均衡性

- ・ 違反ユーザの割合は1%以下と極端に不均衡

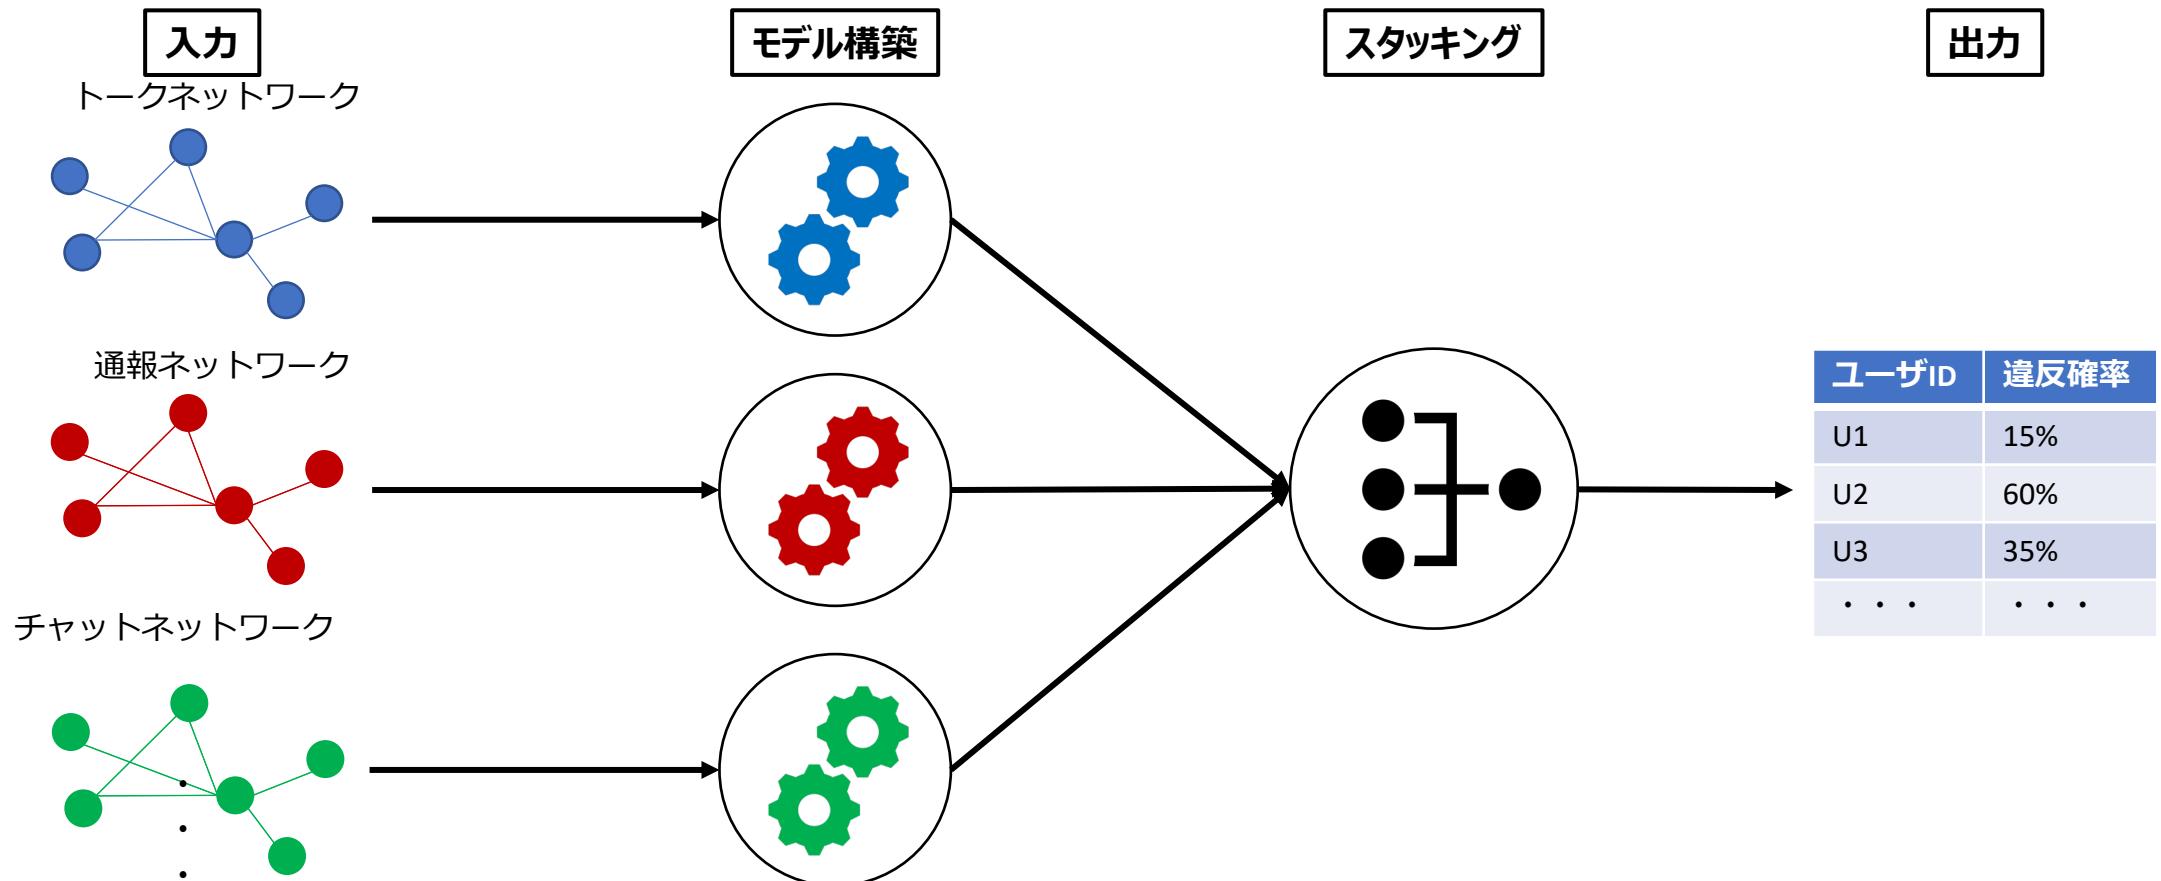
システムの仕組み（データの流れと役割）

- 違反ログと、ユーザIDが暗号化された行動ログ（テキスト以外）を受け取る
- 検知システムは推論結果を返す
- 全自動ではなく、有人監視による最終ジャッジ



モデル構築の流れ

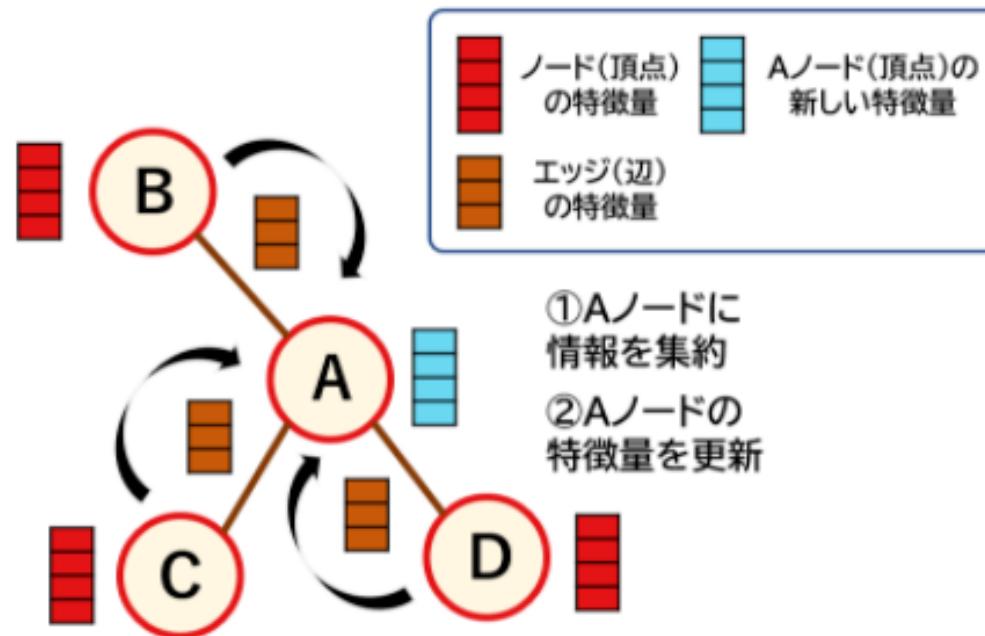
- 様々なユーザ関係ネットワークを利用した、クラス分類問題による検知
- 個人間メッセージ含め、個人情報を一切必要としない
- ネットワークごとにモデル構築し、スタッキングにより統合利用



モデル構築手法：Graph Attention Networks (GAT)

- ネットワークデータに対するディープラーニング系手法の1つ
 - ・ ノード：ユーザの特徴量（性別、年代、インストール日など）
 - ・ エッジ：ユーザ同士の何かしらの繋がり（フレンド関係、ブロック関係など）
- 自身のノードの持つ特徴量と、直接繋がりのある近接ノードの特徴量を考慮（畳み込み演算）
- 繋がりの重要性をエッジの重みとして学習（アテンションメカニズム）

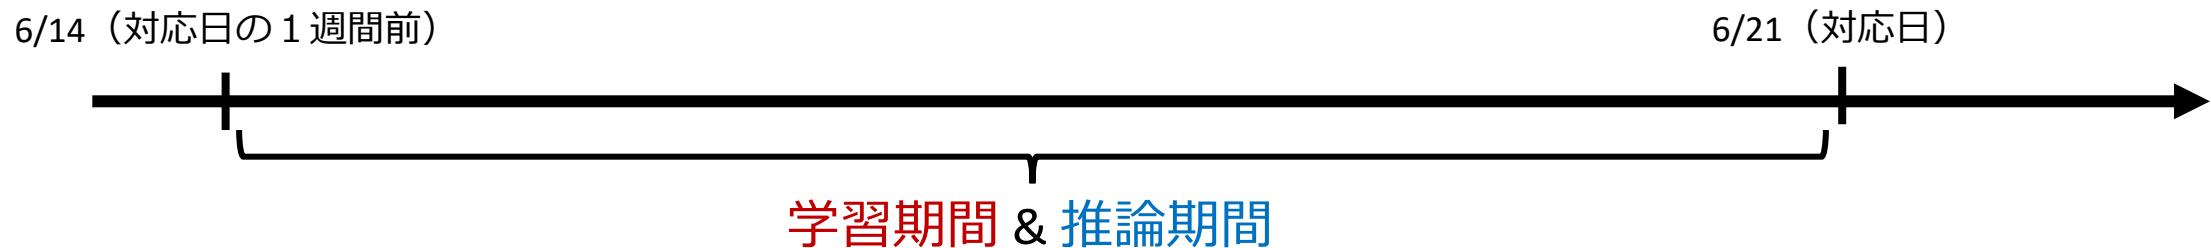
図. ユーザAの学習過程のイメージ



設定タスク 学習期間

- 直前 1 週間のデータを利用して学習 & 推論
- 違反履歴のあるユーザは、違反前と違反後で別のユーザとして扱う
- 違反前のデータは推論には利用しない

【直前 1 週間で違反のないユーザ】



【直前 1 週間で違反したユーザ】



利用するデータ：ユーザ関係ネットワーク

- 6つの行動タイプからネットワークを作成
- コンテンツの流動性を考慮し、全てユーザ関係ネットワークとして定義

行動タイプ	ネットワーク
トーク	送信ユーザ => (トークルーム) => 受信ユーザ
チャット	発話ユーザ => (パーティルーム) => オーナーユーザ
	発話ユーザ => (お部屋) => オーナーユーザ
フレンドリクエスト	申請したユーザ => 申請されたユーザ
フォロー	フォローしたユーザ => フォローされたユーザ
コメント	コメントしたユーザ => (投稿) => コメントされたユーザ
いいね	いいねしたユーザ => いいねされたユーザ

利用するデータ：ユーザ（ノード）の特徴量

特徴量	要素
年代	不明、10歳以下、12歳以下、15歳以下、18歳以下、22歳以下、30歳以下、50歳以下、それ以上でカテゴライズ
性別	不明、男、女
フレンド数	予測実行時点のトータルフレンド数
インストール後経過日数	0日、3日以内、7日以内、14日以内、それ以上でカテゴライズ
各アクションの有無	<ul style="list-style-type: none">入場した回数（エリア、お部屋、パーティ、その他を区別）チャット投稿数（エリア、お部屋、パーティ、その他を区別）入場した場所数（エリア、お部屋、パーティ、その他を区別）チャット投稿した場所数（エリア、お部屋、パーティ、その他を区別）フィード投稿数フィード投稿に対するコメント数フィード投稿へのいいね数フォロー数フレンド申請数ギフト送信数パーティ作成数プロフィール閲覧数トークへの投稿数（グループ、プライベートを区別）トークUU数（グループ、プライベートを区別）きゅん数お部屋デコ回数着せ替え回数

対象ユーザ

【対象ユーザ】

- 直前7日間で下記の条件のいずれかを満たすユーザを対象に、それぞれ学習用データセットを作成

トークユーザ数	3以上
チャットしたユーザ数	
フレンド申請数	
フォロー申請数	
コメントしたユーザ数	
いいねしたユーザ数	20以上

- 推論対象ユーザは、直前7日間にログインした全ユーザ（永久BANユーザを除く）

【設定クラス】

- 違反クラス**：対象ユーザのうち、直前1週間で一時BANを受けたユーザ
- 健全クラス**：対象ユーザのうち、直前30日間でペナルティを1度も受けていないユーザ

入力データの基本統計量

- 各ネットワークで分布も対象ユーザも異なる
- 比較的大規模で疎なネットワーク
- クラスのないノードも一定数存在
- 不均衡分類問題

ネットワークタイプ	ノード数	エッジ数	1人あたりエッジ数	違反クラスノード数	健全クラスノード数	クラスなしノード数	違反クラスの割合
リクエスト	46,892	486,258	10.3	244	37,169	9,479	0.7%
チャット	51,151	1,247,344	24.3	344	38,165	12,642	0.9%
トーク	26,764	293,390	10.9	235	18,326	8,203	1.3%
コメント	16,702	163,638	9.7	137	11,544	5,021	1.2%
フォロー	6,324	155,576	24.6	54	4,338	1,932	1.2%
いいね	81,040	10,228,766	126.2	334	66,942	13,764	0.5%

実験設定 モデル全般

【予測実行日】

- 予測対象日：2020年10月14日
- 学習データ期間：2020年10月8日～14日

【テストデータの評価（初心者の行動をうまく学習できたか）】

- 訓練データ7割（うち検証データ3割）、テストデータ3割
- AUCを最も重視して評価
- 予測確率50%以上とした場合の、Accuracy、F1、Precision、Recallも算出
- スタッキング前の、各GATモデルも評価

【人力評価（熟練者を発見できたか）】

- 予測確率が上位のユーザと、ランダムに抽出されたユーザ約2,000人を、有人監視チームが熟練違反者か否かラベル付け
- 評価結果から、適切な予測確率のしきい値を決定

実験設定 GAT

- 損失関数：交差エントロピー誤差
 - 活性化関数：LeakyReLU
 - 最適化関数：Adam SGD
 - エポック数：300
 - 早期停止のチェック間隔：100
 - マルチヘッド数：8
 - 隠れ層の数：1
 - 隠れ層の次元数：8
 - 学習時には、クラス比率に応じたクラスの重みを設定
-
- 以下のパラメータをグリッドサーチして、検証データの損失が最小となるモデルを選択

パラメータ	値
学習率	0.006～0.01 (0.001刻み)
特徴量のドロップアウト率	0.1～0.3 (0.1刻み)
アテンションのドロップアウト率	0.1～0.3 (0.1刻み)
重み減衰の係数	{0.01～0.014} (0.002刻み)
ReLUの負の勾配	{0.1～0.3} (0.1刻み)

実験設定 LightGBM

- スタッキングにはLightGBMを利用
 - 特徴量の欠損値をそのまま利用可能
- 訓練データは、クラス比率が95:5となるように健全クラスをランダムアンダーサンプリング
- さらに、クラス比率が90:10となるように違反クラスをSMOTEオーバーサンプリング
- 学習時には、クラス比率に応じたクラスの重みを設定
- 以下のパラメータをグリッドサーチして、検証データのAUCが最小となるモデルを選択

パラメータ	値
基本学習器の数	5～51（5刻み）
特徴学習率	0.025～0.05（0.005刻み）
葉ノードの数	2～10（2刻み）
1つの基本学習器の最大深さ	2～10（2刻み）
1つの葉ノードに必要な最小サンプル数	10～30（10刻み）

実験結果（テストデータによる評価）

- スタッキング（ALL）によるAUCが最も高く、0.932と高性能
- 違反ユーザは熟練者である可能性もあるので、テスト結果としては十分

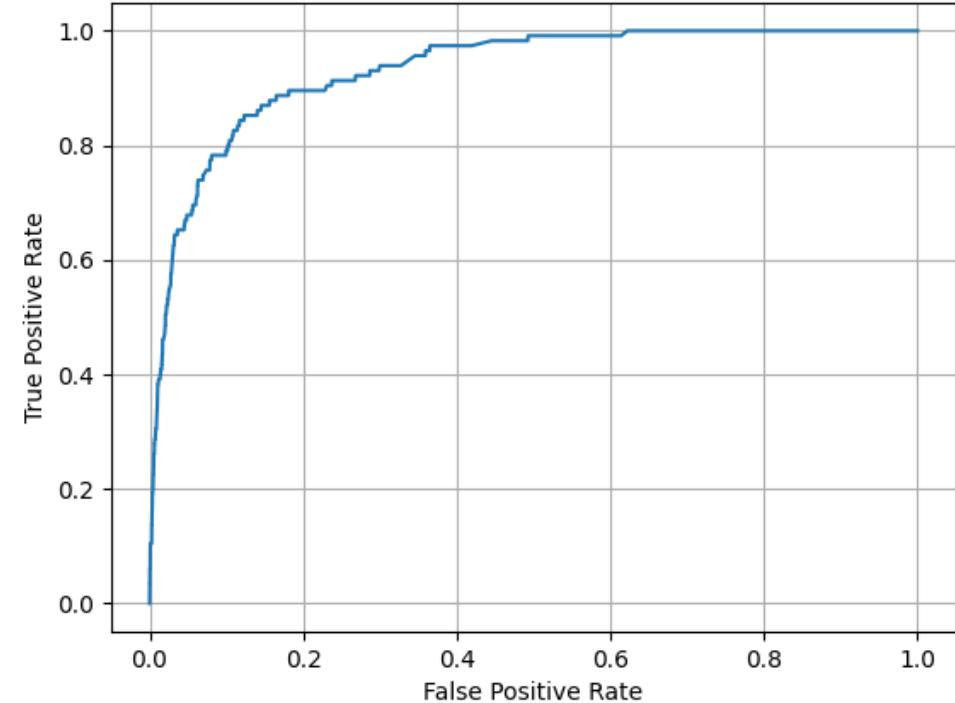
評価値

モデル	Accuracy	Precision (違反)	Recall (違反)	F1 (違反)	AUC
リクエスト	0.827	0.021	0.575	0.041	0.790
チャット	0.830	0.032	0.612	0.060	0.790
トーク	0.836	0.040	0.521	0.075	0.754
コメント	0.801	0.034	0.585	0.064	0.769
フォロー	0.926	0.045	0.250	0.076	0.690
いいね	0.721	0.014	0.790	0.027	0.825
ALL	0.876	0.033	0.852	0.063	0.932

ALLの分類表 ($\geq 50\%$)

		予測		
		健全	違反	合計
実測	健全	20,310	2,885	23,195
	違反	17	98	115
	合計	20,327	2,983	23,310

ALLのROC曲線



人力評価 監視の着目ポイントの絞り込み

- 1週間の全ての投稿やDMを有人監視するのはコストが高い
- 「場所」と「相手」、「日付」の3つの観点で監視ポイントの絞り込みを行う

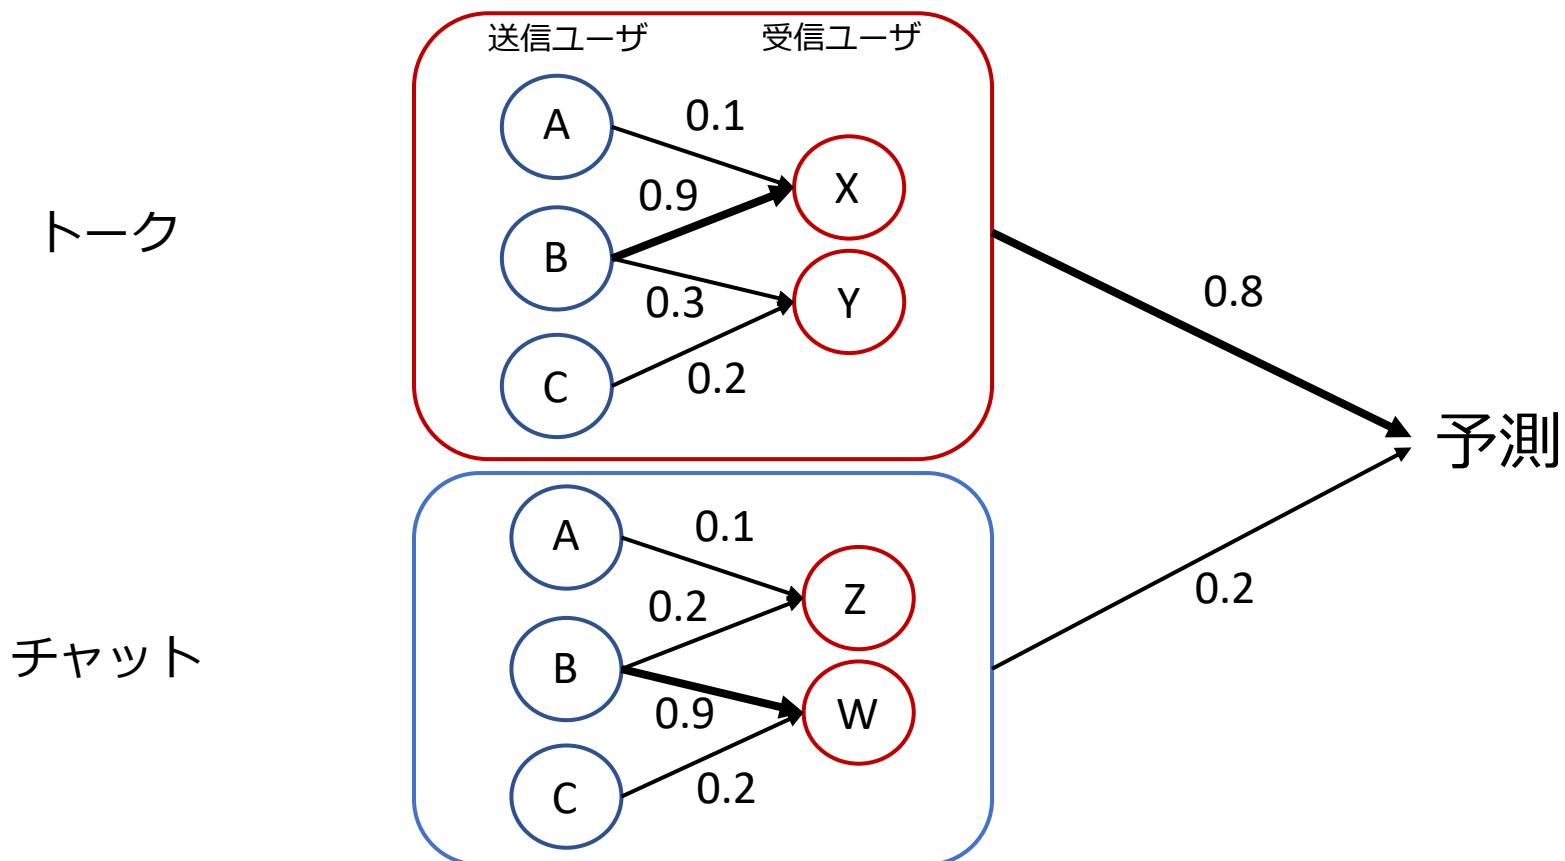


ユーザID（暗号化済み）	予測確率	着目ポイント
u_0001	98.8%	{'place': 'talk', 'id': [57947691, 8239123, ···], 'date': 2020/10/13}
u_0002	95.1%	{'place': 'room', 'id': [3659822, 37529123, ···], 'date': 2020/10/13}
u_0003	80.2%	{'place': 'party', 'id': [2480173, 8239123, ···], 'date': 2020/10/13}
u_0004	70.7%	{'place': 'area', 'id': [57947691, 8239123, ···], 'date': 2020/10/13}
u_0005	70.5%	{'place': 'talk', 'id': [57947691, 8239123, ···], 'date': 2020/10/13}

表. システムが返す結果例

監視の着目ポイントの絞り込み

- アテンション係数 : 相手の絞りこみに利用
- 各GATモデルの予測確率 : 場所の絞り込みに利用
- ログイン履歴 : 時間の絞り込みに利用



まとめと今後

【まとめ】

- SNS上の「誘い出し加害者」と「いじめ被害者」の2つの汎用検知システムを構築
- 様々な問題をクリアした現実的な仕組みを確立
 - ・ 主にユーザ関係ネットワークを利用して配慮することで、**プライバシー**に配慮
 - ・ 有人監視を加えることで、**AIの限界**に配慮
 - ・ スタッキングにより、**SNSの多様性**を考慮
 - ・ ユーザ関係ネットワークに変換することで、**コンテンツ流動性**を緩和
 - ・ オーバー/アンダーサンプリングとクラス重みによる**不均衡データ**への対応
- 本番運用まで見据えた共同研究による迅速な社会実装

【今後】

- 本番運用を行うことで、現場の声を取り入れた継続的な改善
- 事業化し、様々なSNS、ライブ配信アプリ、およびマッチングアプリに横展開